

RESSOURCE · LE COÛT DE TES AGENTS

Mesure ce que coûtent vraiment tes agents.

Un abonnement ne compte rien : le jour où les règles changent, ce qui coûtait zéro devient une facture. Voilà les trois nombres à suivre, le script qui les calcule, et les trois causes de dérive.

- Ce qu'on a trouvé en convertissant six jours au tarif à l'usage.
- Les trois nombres à suivre par boucle d'agent.
- Le script de coût, avec son fichier d'entrée et sa sortie.
- Les trois causes de dérive, et ce qui les coupe.

Rien à installer : un fichier de journal, un script de vingt lignes, et le rapport de fin de session de ton agent.

L'abonnement cache le compteur.

Personne chez nous ne savait ce que consommait une boucle. On a converti six jours de sessions au tarif de l'API, celui qu'on paierait à la consommation.

Ce que disait la facture	Ce que disait la mesure
0 € de plus que l'abonnement	2 480 \$ d'équivalent sur six jours
Aucun compteur visible	43 % relecture de contexte, 43 % écriture, 14 % texte produit
Un usage « normal »	neuf dixièmes du coût à porter le contexte

Pourquoi ça compte quand même

Le risque arrive le jour où l'abonnement ne couvre plus les boucles automatiques. Le 4 avril 2026, Anthropic a déjà coupé l'usage des abonnements par les outils tiers.

Le marché ne fait pas mieux

Selon ICONIQ, en juillet 2026, 68 % des entreprises ne savent pas prédire le coût de leurs agents. Un flux budgété à 0,10 \$ par exécution a dérivé au-delà de 1,50 \$.

Ce qu'on suit, par boucle.

Ce qui se mesure	Ce qui ne se mesure pas
Jetons d'entrée, de sortie, de contexte	le temps passé par l'agent
Nombre de résultats produits	le nombre de messages échangés
Coût par résultat, semaine après semaine	l'impression que « ça travaille »

Jetons par exécution

Entrée, sortie et contexte réutilisé, pour un passage complet. C'est la matière première du calcul.

Part de contexte

Ce qui sert à relire et réécrire ce que l'agent sait déjà. Au-delà des trois quarts, il y a du ménage à faire dans ce qu'on lui charge.

Coût par résultat

Par fiche préparée, par liste livrée, par page publiée. C'est le seul chiffre comparable d'un mois sur l'autre.

Trois nombres suffisent. Une comptabilité plus fine coûte plus de temps qu'elle n'en fait gagner.

Le coût par résultat, en vingt lignes.

Une ligne par passage dans un fichier de journal, et ce script rend le coût total et le coût par résultat. Les tarifs se mettent à jour à la main.

Adapter les tarifs

Les trois lignes de prix se mettent à jour à la main, depuis la page tarifaire de ton fournisseur. Date la mise à jour en commentaire.

Adapter les noms

« grand », « moyen », « petit » : mets les noms de tes modèles. Le script ne sait rien d'autre d'eux que leur prix.

scripts/cout.py

```
import json, sys

PRIX = { # $ par million de jetons
    "grand": {"entree": 5, "sortie": 25},
    "moyen": {"entree": 2, "sortie": 10},
    "petit": {"entree": 1, "sortie": 5}}

total, resultats = 0.0, 0
for l in open(sys.argv[1]):
    p = json.loads(l)
    t = PRIX[p["modele"]]
    cache = p.get("cache", 0) * t["entree"] * 0.1
    cout = (p["entree"] * t["entree"]
            + p["sortie"] * t["sortie"] + cache) / 1e6
    total += cout
    resultats += p.get("resultats", 0)

print(f"total {total:.2f} $ pour {resultats} résultats")
print(f"par résultat : {total / max(resultats, 1):.2f} $")
```

Le contexte réutilisé est facturé environ un dixième du tarif d'entrée : d'où le coefficient 0,1.

Le journal, une ligne par passage.

Les nombres viennent du rapport de fin de session de ton agent. Une ligne par passage, écrite à la main au début, puis par l'agent lui-même.

Où trouver les jetons

Dans le rapport de fin de session de ton agent, ou dans le journal de l'API si tu passes par elle.

Le piège du zéro

Un passage à zéro résultat n'est pas gratuit : il apparaît dans le total et fait monter le coût par résultat. C'est voulu.

`exemples/passages.jsonl`

```
{"modele":"moyen","entree":120000,"sortie":9000,
  "cache":80000,"resultats":3}
{"modele":"grand","entree":60000,"sortie":4000,
  "cache":150000,"resultats":1}
{"modele":"petit","entree":30000,"sortie":2000,
  "cache":0,"resultats":4}
```

```
$ python3 cout.py exemples/passages.jsonl
total 0.86 $ pour 8 résultats
par résultat : 0.11 $
```

« resultats » est le nombre de choses réellement produites par ce passage, au sens de ton métier.

Trois causes, et ce qui les coupe.

La dérive la plus fréquente

Le contexte. Il grossit sans prévenir, à mesure qu'on ajoute des notes, des outils et des règles chargés au démarrage.

Le réglage qui rapporte le plus

Charger à la demande. L'agent ouvre ce dont il a besoin au lieu de tout recevoir, et le coût baisse sans rien perdre.

La cause	Ce qui la coupe
Les relances : l'agent réessaie sans limite	un nombre maximal d'essais, écrit dans son brief
Le contexte qui gonfle : tout est chargé	charger à la demande, pas au démarrage
Le grand modèle partout, par défaut	petit modèle pour exécuter, grand pour juger

L'ordre de grandeur à connaître

Une session deux fois plus longue coûte souvent quatre fois plus : le contexte se relit à chaque échange. C'est la raison pour laquelle on coupe une session et on repart d'une note, plutôt que de continuer indéfiniment.

Une seule modification à la fois, et on remesure la semaine suivante. Deux changements simultanés ne s'attribuent plus.

Quatre gestes cette semaine.

1

Garder les rapports de fin de session

Le tien les affiche déjà. Copie les trois nombres dans le journal, une ligne par passage.

2

Écrire le nombre de résultats

Ce que le passage a produit, au sens de ton métier. Sans lui, le coût n'est comparable à rien.

3

Lancer le script chaque semaine

Trente secondes. Tu cherches une tendance, pas une comptabilité au centime.

4

Décider une chose

Un modèle plus petit sur la boucle la plus chère, ou moins de contexte chargé. Une seule modification à la fois, sinon tu ne sauras pas ce qui a agi.

Le temps que ça prend

Dix minutes la première fois, deux minutes par semaine ensuite. C'est le prix d'un chiffre qu'on peut opposer à une impression.

Quand s'arrêter

Quand le coût par résultat est stable trois semaines de suite. Tu sauras alors ce que coûte vraiment chaque nouvelle boucle.

Le tableau à tenir

Une ligne par semaine : coût total, nombre de résultats, coût par résultat. Trois colonnes suffisent à voir une dérive avant qu'elle devienne une facture.

Trois phrases à garder.

- Un coût à 0 € est un coût non mesuré, pas un coût nul.
- Trois nombres par boucle : jetons, part de contexte, coût par résultat.
- Petit modèle pour exécuter, grand modèle pour juger.
- Une session deux fois plus longue coûte souvent quatre fois plus.

Par où commencer

Convertis une semaine de ton usage au tarif à l'usage. Le chiffre suffit à décider de ce qu'il faut corriger.

Le piège

Optimiser avant de mesurer. La plupart des économies viennent du contexte chargé, pas du modèle choisi.

Quand tu veux aller plus loin

Ce que tu ajoutes

Le coût varie sans raison claire

le détail par boucle, et non plus le total

Une boucle coûte plus qu'elle ne rapporte

un seuil d'arrêt automatique, écrit dans son brief

Tu veux comparer deux modèles

le même journal, deux semaines, une seule variable changée

Combien coûte une exécution de ta boucle la plus fréquente ? Réponds à mon message, on regarde où part l'argent.