

RESSOURCE · LE COÛT DE TES AGENTS

Le vrai coût de tes agents IA, par résultat, en 30 minutes.

Un abonnement ne compte rien : le jour où les règles changent, ce qui coûtait zéro devient une facture. Ton agent calcule ici ce que valait ta semaine au tarif à l'usage, et ce que coûte chaque résultat.

- Un coût à 0 € est un coût non mesuré, pas un coût nul.
- Trois nombres : les jetons, la part de contexte, le coût par résultat.
- C'est l'agent qui écrit le programme et lit ton historique.
- À la fin : le coût de ta semaine, et une seule chose à changer.

Aucune ligne de commande. Chaque bloc gris se copie tel quel dans la fenêtre de Claude.

L'abonnement cache le compteur.

On a converti six jours de nos sessions au tarif de l'API, celui qu'on paierait à la consommation. La facture disait 0 € de plus que l'abonnement.

Ce que disait la facture	Ce que disait la mesure
0 € de plus que l'abonnement	2 480 \$ d'équivalent sur six jours
Aucun compteur visible	43 % relire le contexte, 43 % le réécrire, 14 % le texte produit
Un usage « normal »	86 % du coût à porter le contexte, pas le travail

Pourquoi ça compte

Le 4 avril, Anthropic a coupé l'usage des abonnements par les outils tiers. Et selon ICONIQ, en juillet 2026, 68 % des entreprises ne savent pas prédire le coût de leurs agents.

La règle qu'on en a tirée : un petit modèle pour exécuter, le grand pour juger.

Ouvre un dossier pour tes comptes.

1

Installe Claude

Si ce n'est pas fait : claude.ai/download, installe l'application pour Mac ou Windows, connecte-toi.

2

Crée le dossier

Dans Documents, clic droit, « Nouveau dossier », appelle-le mes-couts.

3

Ouvre-le dans l'onglet Code

Clique sur Code, choisis « Local », sélectionne mes-couts, et prends le mode « Manual » : l'agent te demande avant chaque modification.

Tu dois voir : une zone de message, avec le nom du dossier mes-couts affiché.

Le programme de coût, écrit par l'agent.

Copie ce message tel quel. Les prix viennent de la page officielle, jamais de sa mémoire : un chiffre faux ici fausse tout le reste.

Message à envoyer

1. Va lire la page des tarifs de l'API d'Anthropic. Écris dans `tarifs.md` le prix par million de jetons de chaque modèle : entrée, sortie, cache. Date-la.
2. Crée `journal.csv`, une ligne par session :
date, modèle, jetons d'entrée, de sortie, de cache, nombre de résultats.
3. Écris un petit programme `cout` qui lit le journal et `tarifs.md`, puis affiche : coût total, part du contexte, coût par résultat. Teste-le sur trois lignes d'exemple, puis vide le journal.

Tu dois voir : `tarifs.md` avec une date, `journal.csv` vide, et le programme `cout` qui a affiché un total sur l'exemple.

Ta vraie semaine, au tarif à l'usage.

Ton historique de sessions est déjà sur ton ordinateur. Remplace ce qui est entre chevrons par ce que l'agent a produit, puis envoie.

Message à envoyer

```
Lis l'historique local de mes sessions Claude Code
des 7 derniers jours. Pour chaque session, ajoute
une ligne à journal.csv avec ses jetons et son modèle.
Résultats de la semaine : <ce qui est sorti>.
Répartis-les sur les sessions concernées,
et mets 0 aux autres. Puis lance cout.
```

La ligne des résultats, remplie

```
Résultats de la semaine : 3 fiches d'appel,
1 liste de prospects, 2 relances de devis.
```

Tu dois voir : le coût total de ta semaine, la part du contexte, et le coût par résultat. Une session à zéro résultat n'est pas gratuite : elle fait monter la moyenne, c'est voulu.

Une seule chose à changer.

Copie ce message tel quel. On ne change qu'une chose à la fois : à deux changements, tu ne sauras plus lequel a agi.

Message à envoyer

Quelle session coûte le plus par résultat ?
Dis-moi laquelle des trois causes l'explique :
des essais répétés, un contexte qui gonfle, ou le
grand modèle là où un petit suffisait.
Propose une seule modification, et écris-la
dans decisions.md avec la date.

La cause	Ce qui la coupe
Il réessaie sans limite	Un nombre maximal d'essais, écrit dans ses consignes
Le contexte gonfle	Couper la session, repartir d'une note courte
Le grand modèle partout	Petit modèle pour exécuter, grand pour juger

Tu dois voir : la session la plus chère, sa cause, et une décision datée. C'est ton résultat. Relance le calcul dans une semaine pour voir l'effet.

Trois phrases, et la suite.

- Un coût à 0 € est un coût non mesuré, pas un coût nul.
- On compte le coût par résultat, pas le coût total.
- Une session deux fois plus longue coûte souvent quatre fois plus.

Et après ?

Chaque semaine, dis à l'agent « mets le journal à jour et lance cout ». Deux minutes, et tu vois une dérive avant qu'elle devienne une facture.

Le piège

Optimiser avant de mesurer. La plupart des économies viennent du contexte chargé, pas du modèle choisi.

Combien t'a coûté ton résultat le plus cher cette semaine ? Réponds à mon message, on regarde où part l'argent.